

RETO OPERACIONAL

1. Introducción

Este documento contiene la descripción del reto operacional que afrontaran los participantes. Las bases de datos utilizadas son sintéticas y anonimizadas, adaptadas de las bases operacionales brindadas por las empresas prestadoras de la macroregión. Para la adaptación de las bases sintéticas, se han ajustado el tamaño y las variables para homogenizar el reto por regiones.

2. Descripción del problema y de los datos

2.1. Antecedentes

La empresa prestadora de servicios de agua potable y saneamiento (EPS) de tu región gestiona más de 300,000 conexiones activas entre usuarios sociales, domésticos, comerciales, industriales y estatales. En el marco de su proceso operacional, la EPS ha consolidado información correspondiente a roturas de tubería matrices y fugas de agua. Esta información incluye variables clave como conexión más cercana a la rotura o fuga, sector, fecha y ubicación geográfica de los casos. No obstante, evaluaciones internas han evidenciado limitaciones significativas en la calidad, consistencia y aprovechamiento de la información disponible, lo cual restringe la toma de decisiones estratégicas.

2.2. Problemática

La EPS enfrenta desafíos críticos en tres dimensiones principales:

A. Calidad e integridad de la información

Se han identificado inconsistencias estructurales en la base de datos, tales como:

- Duplicidad de información (Sobre registro de fugas y roturas)
- Presencia de Outliers
- Inconsistencias en coordenadas geográficas (conexiones con coordenadas fuera del área de cobertura)

Estas deficiencias afectan la confiabilidad de los sistemas de información operacional.

B. Consolidación de información

La red de distribución de la EPS presenta un comportamiento heterogéneo entre sectores, donde la combinación de indicadores de roturas, fugas y caudales hace difícil identificar cuáles requieren atención prioritaria. Ante ello, se propone un análisis de clúster que agrupe los sectores según su perfil operativo conjunto, permitiendo caracterizarlos y focalizar los recursos de mantenimiento en aquellos con condiciones más críticas.

C. Atención optimizada de roturas y fugas

Desde una perspectiva estratégica, las EPS enfrentan el desafío de avanzar hacia el establecimiento de una ruta optima diaria de solución de roturas y/o fugas que minimice el desplazamiento de los trabajadores encargados de esta labor y por lo tanto reducir los costos de la empresa sin desmedro de la calidad del servicio. En ese sentido se requiere un plan optimizado de ruta o senda óptima para solucionar roturas (fugas) diarias

2.3. Descripción de las bases de datos

5 archivos en formato excel con información de: caudales, roturas y fugas, roturas no visibles, longitud de redes y número de conexiones. Cada archivo compartido contiene lo siguiente:

2.3.1. Base de Caudales por Sectores

Base de datos con información de caudales mensuales registrados por macromedidores en cada sector operacional de la EPS, correspondiente al año 2025.

Atributo	Detalle
REGIÓN	Región donde se ubica la empresa prestadora
Archivo	01_BASE CAUDALES_SECTORES_EPS.xlsx
Periodo de análisis	Año 2025 (enero a diciembre)
Tamaño aproximado	400 registros
Unidad de observación	Sector operacional
Hoja principal	Hoja1

2.3.1.1. Variables clave

A continuación, se describen las variables contenidas en esta base de datos:

Variable	Descripción
<i>SECTOR</i>	Sector con información sobre su caudal
<i>MACROMEDIDOR</i>	Tipo o marca del macromedidor instalado en el sector
<i>ene, feb, ..., dic</i>	Caudal promedio mensual registrado (l/s) para cada mes del año
<i>PROMEDIO</i>	Caudal promedio anual calculado (l/s)

2.3.2. Base de Roturas en Red Primaria y Secundaria

Base de datos con el registro de incidencias de roturas en la red primaria (tubería matriz) y en la red secundaria (conexiones domiciliarias, fugas), incluyendo ubicación georreferenciada y clasificación por tipo de evento.

Atributo	Detalle
REGIÓN	Región donde se ubica la empresa prestadora
Archivo	02_ROTURAS_RED_PRIMARIA_SECUNDARIA_EPS.xlsx
Periodo de análisis	Año 2025 (enero a diciembre)
Tamaño aproximado	926 registros (red principal) + 15,159 registros (red secundaria)
Unidad de observación	Incidencia de rotura o fuga
Hojas principales	ROTURAS RED PRINCIPAL, FUGAS RED SECUNDARIA

2.3.2.1. Variables clave

A continuación, se describen las variables contenidas en esta base de datos:

Variable	Descripción
CONEXION	Código numérico de la conexión asociada al evento
CDESSER	Descripción del servicio específico (ej. Rotura de tubería matriz, Fuga en llave de paso)
SECTOR	Sector donde ocurrió el evento
MES	Número y nombre del mes del evento
AÑO	Año del evento (2025)
CATEGORIA	Clasificación del tipo de evento (Rotura Tubería Matriz, Fuga, etc.)
fecha_inicio	Fecha de registro de la Rotura (Fuga).
hora_inicio	Hora a la que se registró el evento.
fecha_fin	Fecha en la que finalizó las actividades de reparación (Fuga).
hora_fin	Hora a la que finalizó las actividades de reparación.
LATITUD / LONGITUD	Coordenadas geográficas del evento

2.3.5. Base de Longitud de Red por Sector

Base de datos con la longitud de red de distribución y de aducción por sector operacional, incluyendo el número de conexiones y la fuente de abastecimiento asociada.

Atributo	Detalle
REGIÓN	Región donde se ubica la empresa prestadora
Archivo	06_REDES_CONEXIONES_EPS.xlsx
Periodo de análisis	Año 2025
Tamaño aproximado	400 registros
Unidad de observación	Sector operacional
Hoja principal	Hoja1

2.3.5.1. Variables clave

A continuación, se describen las variables contenidas en esta base de datos:

Variable	Descripción
Sector	Nombre o código del sector operacional
Conexiones	Número total de conexiones en el sector

Variable	Descripción
Fuente	Nombre de la fuente de abastecimiento asociada al sector (ej. La Tomilla, Miguel de la Cuba Ibarra)
Red de Distribución (m)	Longitud total de la red de distribución del sector, en metros
Red de Aducción (m)	Longitud total de la red de aducción del sector, en metros

3. Definiciones importantes

3.1. Fuga vs. Rotura de tubería matriz

Una **fuga** es una pérdida de agua de baja intensidad (litros por minuto) que ocurre en conexiones domiciliarias, llaves de paso o medidores, generalmente no visible bajo tierra, causada por desgaste o corrosión de accesorios, y que afecta la presión de un solo predio. Una **rotura de tubería matriz** es una salida violenta de alto caudal (litros por segundo) en redes primarias o secundarias, casi siempre visible al romper el pavimento, que compromete el servicio de todo un circuito o sector y requiere reparación compleja con excavación mecánica. La diferencia esencial es de escala: la fuga es una pérdida localizada y gradual en la acometida del usuario, mientras que la rotura es un evento súbito de alto impacto en la infraestructura troncal del sistema.

3.2. Sector Operacional

Es la unidad mínima de gestión hidráulica. Se define como un área de la red de distribución técnicamente aislada por válvulas de frontera, donde el ingreso de agua está controlado por uno o más macromedidores. Su objetivo es facilitar el control de presiones y la localización de fugas.

3.3. Caudal

Es la razón de flujo o volumen de agua que atraviesa una sección transversal de la tubería por unidad de tiempo.

3.6. Senda óptima

La senda óptima es la secuencia de visitas a un conjunto de puntos que minimiza la distancia total recorrida desde un origen fijo, garantizando que cada punto sea atendido exactamente una vez antes de pasar al siguiente. Este problema, conocido en optimización combinatoria como el Problema del Viajero, busca encontrar el orden de atención más eficiente dado un criterio de distancia.

3.7. Macromedidor

Es el conjunto de equipos instalados en puntos estratégicos de la red (salida de reservorios o estaciones de bombeo) destinados a cuantificar el volumen de agua inyectado a un sector. (Nota Arkon Electromagnético": Se refiere a un flujómetro basado en la Ley de Faraday. Es la tecnología de punta en saneamiento debido a que no tiene partes móviles, no genera pérdida de carga (presión) y posee una alta precisión (R200 o superior), lo cual es crítico para detectar fugas mínimas).

3.14. Distancia Euclidiana

La Distancia Euclidiana es la medida más común de separación entre dos puntos en un espacio geométrico. Corresponde a la "distancia en línea recta" entre ellos, cómo se define en la geometría clásica basada en el teorema de Pitágoras.

4. Descripción de los retos

4.1. Reto 1: Limpieza de base de datos

El primer reto consiste en detectar y corregir dos tipos de inconsistencias presentes en las bases de datos: registros duplicados y coordenadas geográficas con orden invertido. A continuación, se describe cada anomalía, su criterio de identificación y la corrección aplicada.

4.1.1. Anomalías en los datos

Se identifican tres tipos de anomalías en el proceso de registros de eventos operativos:

- **Caso 1 — Duplicidad en la base de roturas y fugas:** Existencia de sobreregistros basados en aspectos de conexión, tipo de rotura o corte y fecha de registro.
- **Caso 2 — Denominación de Sectores no uniforme:** Consiste en identificar y corregir el código del sector, debido a que su denominación no es uniforme ("s3", "S-24", "S 55", " S74", "S75 ", "S081"), con el fin de expresarlos de la manera correcta (S1,S2,S3,...Sn)
- **Caso 3 — Presencia de outliers en la base de caudales:** Consiste en identificar los outliers presentes en la base de Caudales, considerando como outlier aquellos valores superiores a $Q3^1 + 1.5RI^2$. Luego corregir los outliers dividiendo los valores entre 10.

El reto consiste en reconocer dicho patrón de sobreregistros y depurar las bases conservando únicamente la información válida.

4.1.4. Inconsistencias geográficas

Toda conexión del sistema cuenta con una ubicación geográfica registrada. Sin embargo, se ha detectado que ciertos registros presentan una anomalía en sus coordenadas que los ubica en una posición incorrecta o incluso fuera del área de servicio. El desafío está en identificar el patrón detrás de este error y corregirlo.

4.2. Reto 2: Consolidación de información a nivel de sector

La gestión eficiente de una red de agua potable requiere que la información operativa se encuentre organizada de manera coherente y centralizada. Por tanto, el presente reto propone que los participantes consoliden las distintas bases de datos en una sola a nivel de sector, lo que facilitará la construcción de indicadores operativos que permitan diagnosticar el estado real de la red y orientar la toma de decisiones de la empresa prestadora. Para ello se piden los siguientes indicadores para la toma de decisiones:

4.2.1 Ranking de roturas y fugas por sector

Determinar los sectores con mayor número de roturas y fugas por red principal y secundarias. Presentar una tabla con el ranking de Sectores, de mayor a menor incidencia, para identificar de forma directa los sectores con mayor presión operativa.

4.2.2 Cálculo del tiempo de reparación

Con el fin de evaluar la capacidad de respuesta de una EPS ante eventos de roturas y fugas, se debe evaluar el tiempo en el cual se toman para restablecer el servicio. En este caso, se debe determinar el tiempo promedio, total y por sector, que le toma a la EPS reparar las roturas y fugas. Esto debe permitir identificar sectores con demoras sistemáticas.

4.2.3 Normalización de casos

¹ Percentil 75 del Caudal promedio mensual registrado (l/s)

² Rango intercuartílico (Q3-Q1)

Cálculo del número de roturas de redes principales por km de red y número de roturas de redes secundarias por conexiones. Evaluar si existe correlación entre ambos tipos a nivel de sector. Presentar una tabla de doble entrada, sectores y tipo (rotura y fuga); de ser posible agregar un gráfico de dispersión en la presentación.

4.2.4 Análisis de agrupamiento

Desde el punto de vista operativo, no todos los sectores presentan el mismo nivel de criticidad, por lo que resulta necesario clasificarlos en grupos homogéneos que permitan orientar la toma de decisiones de manera diferenciada.

Definición y enfoque

El análisis de agrupamiento o clúster consiste en clasificar los sectores en grupos internamente similares y externamente distintos, utilizando como variables de entrada los indicadores de caudales y de roturas (roturas/km) y fugas (fugas/mil conexiones) construidos en los puntos anteriores. Previo a la clasificación, se debe determinar el número óptimo de grupos mediante algoritmos de optimización, tales como el método del codo o el índice de silueta, disponibles en librerías como sklearn en Python o cluster: silhouette() y kmeans en R.

4.3. Reto 3: Calculo de fugas atendidas por cada cuadrilla

La EPS cuenta con cuadrillas de reparación de fugas en tres ubicaciones:

Región	Código	Latitud	Longitud
Cuadrilla 1	C1	-11.99400	-77.07831
Cuadrilla 2	C2	-12.05113	-77.03430
Cuadrilla 3	C3	-12.14258	-76.99109

El reto consiste en identificar que grupo de fugas de los días 24/04/25, 25/04/25, 26/04/25, 27/04/25 debe ser atendido por cada una de las cuadrillas. El criterio de asignación se basa en la distancia euclidiana más cercana a la ubicación de cada cuadrilla, es decir se debe identificar a que cuadrilla se encuentran más cercanas dichas fugas.

4.4. Reto 4: Calculo de la senda optima de reparaciones por cuadrilla

En el contexto operativo de la empresa prestadora, esta cuenta con trabajadores que deben desplazarse diariamente desde su sede central hacia los puntos donde se han reportado fugas en la red. En ese sentido, con el objetivo de minimizar costos de operación, es necesario determinar la senda óptima que permita minimizar la distancia euclidiana recorrida como tal para cada cuadrilla.

4.3.1. Definición y enfoque

El reto consiste en identificar la senda que minimice el desplazamiento (euclidiano) de los trabajadores de la EPS desde la ubicación de cada cuadrilla para la reparación de las fugas de un día. Realizar el ejercicio por los 4 días señalados previamente. Es necesario precisar que el recorrido debe ser completo, es decir, atender todas las roturas, una a una, en un día, partiendo desde cada Ci y retornando al final al lugar de partida. Presentarlo de la siguiente forma:

Día	R1	R2		Rn-1	Rn
24/04/25					
25/04/25					
26/04/25					

27/04/25					
----------	--	--	--	--	--

5. Entregables

¿Qué debe entregar el equipo?

El equipo debe entregar únicamente tres elementos:

- El archivo de script con el código completo, según el lenguaje utilizado:
 - o Un archivo en formato .R si se trabajó en R, o
 - o Un archivo en formato .ipynb si se trabajó en Python.
- El archivo Excel con los resultados (ver sección 5.2).
- La presentación de los resultados (ver sección 5.3).

No se entregan bases de datos ni ninguna carpeta comprimida.

5.1. Script de programación

El script debe contener el código completo y reproducible utilizado para resolver todos los retos, desde la lectura de las bases hasta la generación de los resultados. Se aceptan scripts en R o Python.

El código debe estar comentado y organizado de forma clara.

Además, al inicio del script debe listarse todos los paquetes o librerías utilizados, incluyendo las líneas de instalación comentadas.

Nombre del script (**obligatorio**)

El archivo de script debe nombrarse de la siguiente manera:

solucion_[región]_[nombre de equipo].[R/py/ipynb]

Ejemplo

solucion_arequipa_SSA03.R

NOTA: Solo se considerarán para la evaluación los scripts que tengan el formato y nombre que exactamente como se está solicitando

El nombre del equipo es asignado por los organizadores al inicio del concurso.

5.2. Lista Excel de resultados

Se debe entregar un archivo Excel con los siguientes resultados, cada uno en una hoja separada:

Hoja	Contenido
Observaciones únicas	Tabla de Número de observaciones únicas por tipo de problema
Coordenadas invertidas	Tabla del número de coordenadas invertidas por Sector y tipo de problema
Ranking de roturas	Total de roturas por sector
Ranking de fugas	Total de fugas por sector

Hoja	Contenido
Tiempo promedio de reparación de roturas	Tabla del promedio de reparación de roturas por sector y promedio total
Tiempo promedio de reparación de fugas	Tabla del promedio de reparación de fugas por sector y promedio total
Clasificación por medias	Tabla de sectores, roturas/km, fugas/conexiones, caudal y clasificación a la que pertenece
Matriz de distancias	Matriz de distancia entre el punto de partida y las ubicaciones de las roturas del día indicado

*Junto a las bases sintéticas se agrega los Formato de entrega de los archivos en excel solicitados.

Nombre del archivo Excel (**obligatorio**)

El archivo Excel con los resultados debe nombrarse de la siguiente manera:

solucion_[región]_ [nombre de equipo].xlsx

Ejemplo

solucion_tacna_SSA03.xlsx

NOTA: Solo se considerarán para la evaluación los archivos excel que tengan el formato y nombre que exactamente como se está solicitando

NOTA2: Solo considerar estas regiones textualmente y en minúsculas:

- lima

El nombre del equipo es asignado por los organizadores al inicio del concurso.

5.3. Presentación ejecutiva

Se debe preparar una presentación que comunique los hallazgos más relevantes de forma clara y visualmente atractiva. El formato es libre (PowerPoint, Canva, Dashboard, etc.). La presentación debe incluir como mínimo:

- Mapas geográficos que muestren la distribución espacial de las inconsistencias, los consumos atípicos y los grandes usuarios.
- Tablas resumen de los principales resultados por reto.
- Análisis interpretativo: ¿qué significan los hallazgos para la gestión comercial de la EPS?
- Insights accionables: recomendaciones concretas basadas en los resultados obtenidos.

El formato es LIBRE

6. Entrega

Enviar los 3 entregables como documentos adjuntos al siguiente correo: datathonsunass@sunass.gob.pe

Obligatorio

Poner en el asunto del correo el siguiente formato y todo en mayúsculas

ENTREGA_[REGIÓN]_ [NOMBRE DE EQUIPO]_ OPERACIONAL

Ejemplo

Asunto: *ENTREGA_PUNO_SSA03_OPERACIONAL*

NOTA: Solo se considerarán para la evaluación los correos que tengan el asunto exactamente como se está solicitando

NOTA2: Solo considerar estas regiones textualmente y en mayúsculas:

- LIMA

Criterios para la selección de los finalistas:

- (1) Replicabilidad del script: Facilidad de replicar el script en equipos de otros usuarios.*
- (2) Correcta identificación de errores y solución de los retos (tablas)*
- (3) Tiempo de entrega (para definir en caso de empate)*